

PROJET EDUTECH

Informatique Décisionnelle — EPSI 2026

Dataset : OULAD — Open University Learning Analytics Dataset

Outils : Talend | Python | MySQL | Power BI Desktop

Problématique : Taux d'abandon 31% | Taux d'échec 22%

REALISE PAR:

- NGUEMCHE JOYCE
- VOUNDI ABESSOLO PAUL YVAN KHERAN

1. Fiche Projet

1.1 Contexte & Problématique

EduTech est une plateforme universitaire en ligne (32 593 étudiants, 7 modules, 4 sessions). L'analyse des données révèle un taux d'abandon de 31% et un taux d'échec de 22%, nécessitant une solution décisionnelle pour identifier les causes et intervenir en amont.

Pass	Withdrawn	Fail	Distinction
37,93 %	31,16 %	21,64 %	9,28 %

1.2 Décideurs & Personas

Persona 1 – CEO (Vision stratégique)	Persona 2 – Dir. Opérations (Vision opérationnelle)
Rôle : Prise de décision stratégique Besoins : Vue macro, performance par module Fréquence : Hebdomadaire Niveau tech : Intermédiaire KPIs : Taux abandon, score moyen par module	Rôle : Optimisation opérationnelle Besoins : Identifier étudiants à risque, alertes Fréquence : Quotidienne Niveau tech : Avancé KPIs : flag_a_risque, total_clicks par région

1.3 Questions Métier & Périmètre

- Quel est le taux d'abandon/échec par module et par région ?
- Quels étudiants sont à risque d'abandonner avant la fin du cours ?
- Quel lien entre l'engagement VLE (clics) et le résultat final ?

Périmètre : 2013–2014 | Grain : Étudiant × Module × Évaluation | Toutes régions UK

2. Dataset & Architecture

2.1 Dataset OULAD

Jeu de données réel et anonymisé de l'Open University (UK) — 32 593 étudiants, 7 modules, 4 sessions (2013–2014), +10,6M lignes (VLE). 7 fichiers CSV : studentInfo, studentAssessment, studentVle, courses, assessments, studentRegistration, vle.

2.2 Architecture Décisionnelle (3 Couches)

Alimentation (ETL)	Stockage (DW)	Restitution (BI)
Talend Open Studio 8 + Python 3.12 (pandas) Extraction, nettoyage, transformation des données	MySQL 8 / phpMyAdmin Schéma en étoile edutech_dw 5 tables + 2 Data Marts	Power BI Desktop Dashboard interactif 4 mesures DAX Drill-through & Tooltips

3. Modélisation de l'Entrepôt (Schéma en Étoile)


3.1 Table de Faits

fait_performance_etudiant — Table centrale avec les KPIs calculés :

Colonne	Type	Description
id_student / code_module / code_presentation / id_assessment	<i>FK (INT / VARCHAR)</i>	Clés étrangères vers les 4 dimensions
final_result	<i>VARCHAR</i>	Pass / Fail / Withdrawn / Distinction
score_moyen	<i>DOUBLE (measure)</i>	Moyenne des scores de l'étudiant sur le module
total_clics	<i>INT (measure)</i>	Total des clics sur la plateforme VLE
flag_a_risque	<i>INT (measure)</i>	1 si score < 40 ET clics < 200, sinon 0

3.2 Dimensions & Data Marts

Dimensions	Data Marts (Vues SQL)
• dim_etudiant (id_student, gender, region, imd_band, age_band, disability) • dim_module (code_module + code_presentation, length) • dim_temps (code_presentation, annee, semestre) • dim_evaluation (id_assessment, type, date, weight)	• datamart_performance → CEO Performances par module et session • datamart_risque → Dir. Opérations Étudiants à risque avec profil démographique



4. Processus ETL



4.1 Jobs Talend & Scripts Python

Script / Job	Outil	Résultat	Statut
Clean_StudentInfo	Talend	32 593 lignes	✓ Fonctionnel
Clean_StudentAssessment	Talend	173 912 lignes	✓ Fonctionnel
aggregate_vle.py	Python	28 237 lignes	✓ Fonctionnel
build_fact.py	Python	32 593 lignes	✓ Fonctionnel
import_mysql.py	Python	Toutes tables	✓ Fonctionnel

4.2 Règles de Transformation Clés

- imd_band null/vide → 'Unknown' (éviter valeurs manquantes)

- score null → 0 (étudiant absent ou n'ayant pas rendu)
- total_clics = SUM(sum_click) par étudiant × module
- score_moyen = AVERAGE(score) par étudiant (null → 0)
- flag_a_risque = 1 si score_moyen < 40 ET total_clics < 200, sinon 0




5. KPIs & Dashboard Power BI

5.1 Indicateurs Clés de Performance

KPI	Valeur	Mesure DAX	Interprétation
Score moyen	59,65 / 100	<i>Moy_Score</i>	Performance académique moyenne
Taux d'abandon	31,16 %	<i>Taux_Abandon</i>	1 étudiant sur 3 abandonne
Taux d'échec	21,64 %	<i>Taux_Echec</i>	1 étudiant sur 5 échoue
Étudiants à risque	~6 000	<i>Etudiants_A_Risque</i>	Intervention immédiate requise
Engagement moyen	1 270 clics	<i>AVG(total_clics)</i>	Activité sur la plateforme VLE

5.2 Dashboard Power BI — 3 Pages

- Page 1 — Vue Générale : 6 KPI Cards, graphique à barres (score/module), camembert (résultats), treemap (risque/région), 2 slicers
- Page 2 — Détail Module (Drill-through) : Tableau détaillé filtré par module au clic droit
- Page 3 — Tooltip : Info-bulle enrichie (score moyen + taux abandon) au survol des visuels



5.3 Conclusions Analytiques

- Module FFF : meilleur score — Module AAA : score le plus faible → renforcement nécessaire
- Région Londres : plus forte concentration d'étudiants à risque → actions de soutien ciblées
- 31% d'abandon confirmé → alertes précoces dès la 3e semaine pour flag_a_risque = 1

6. Code Source & Livrables

6.1 Structure du Code Source

Tous les codes sont regroupés dans EduTech_CodeSource.txt (Python ETL + SQL + DAX) :

- Python : clean_studentinfo.py | clean_studentassessment.py | aggregate_vle.py | build_fact.py | import_mysql.py
- SQL : Création tables + contraintes FK + vues Data Marts (edutech_dw.sql)
- DAX Power BI : Taux_Abandon | Taux_Echec | Moy_Score | Etudiants_A_Risque

6.2 Bilan & Recommandations

Livrable	Statut
ETL Talend (2 jobs) + Python (4 scripts)	✓ Terminé
Entrepôt MySQL edutech_dw (5 tables + 4 FK + 2 Data Marts)	✓ Terminé
Dashboard Power BI (3 pages, 4 mesures DAX, 7 visuels)	✓ Terminé
Code source documenté (EduTech_CodeSource.txt)	✓ Terminé

- CEO → Renforcer les modules AAA et EEE (scores les plus faibles)
- Dir. Opérations → Alertes automatiques pour flag_a_risque=1 dès la 3e semaine
- Pédagogie → Répliquer les pratiques des modules FFF et BBB (meilleurs scores)

— Fin du rapport EduTech / EPSI 2026 —